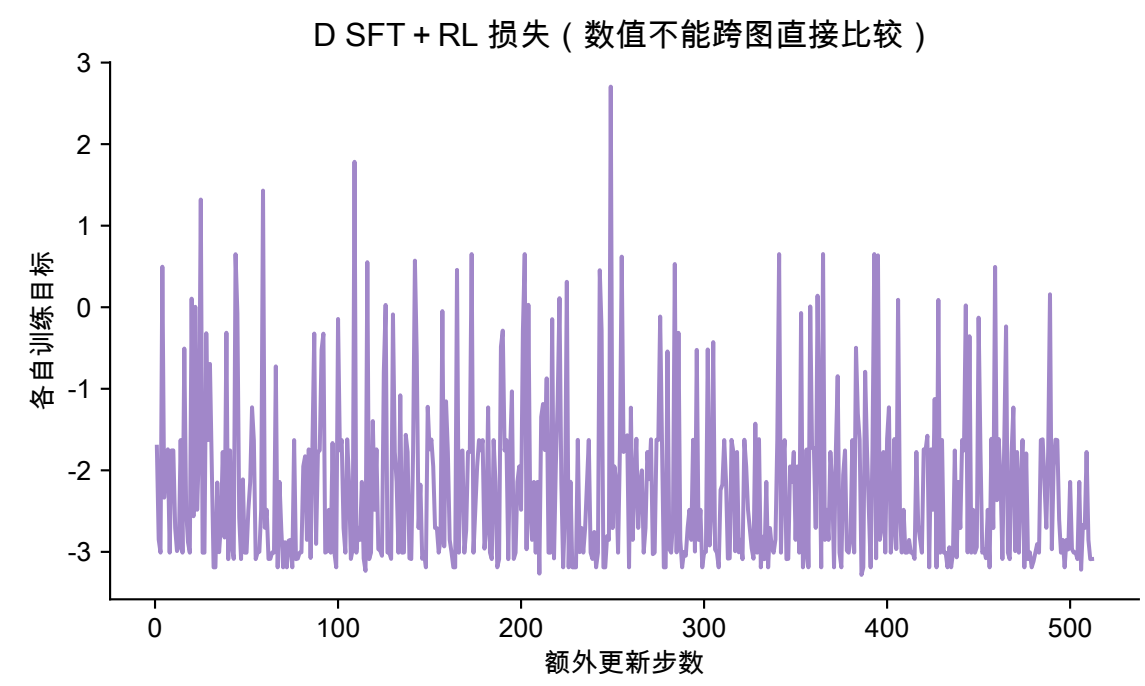
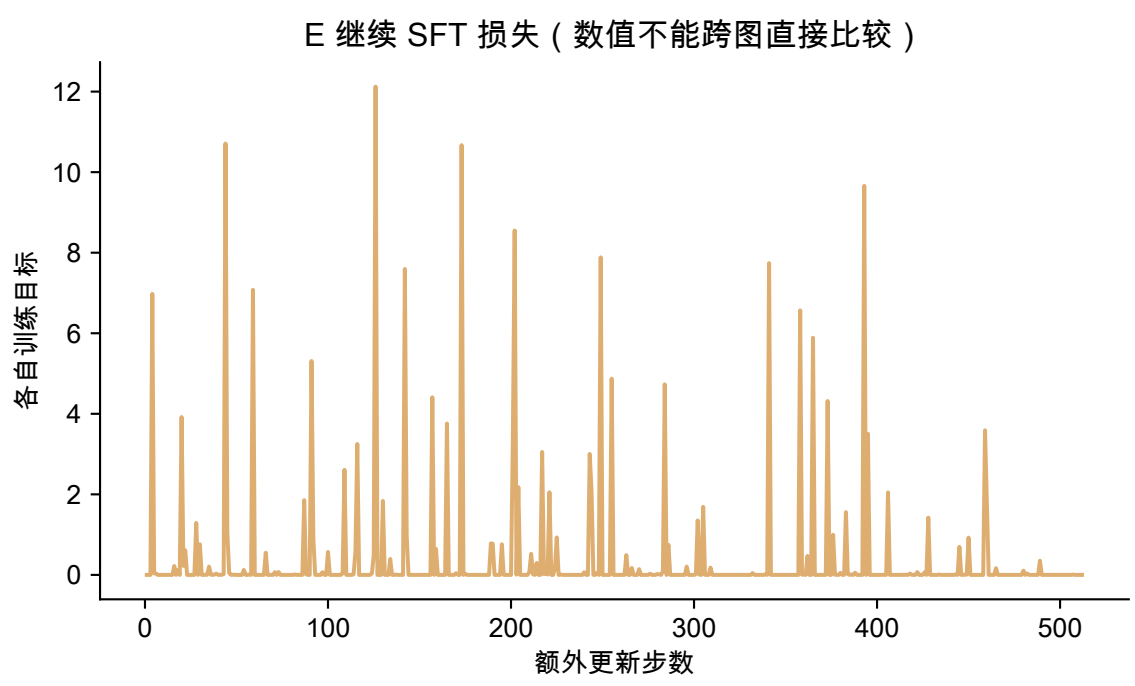
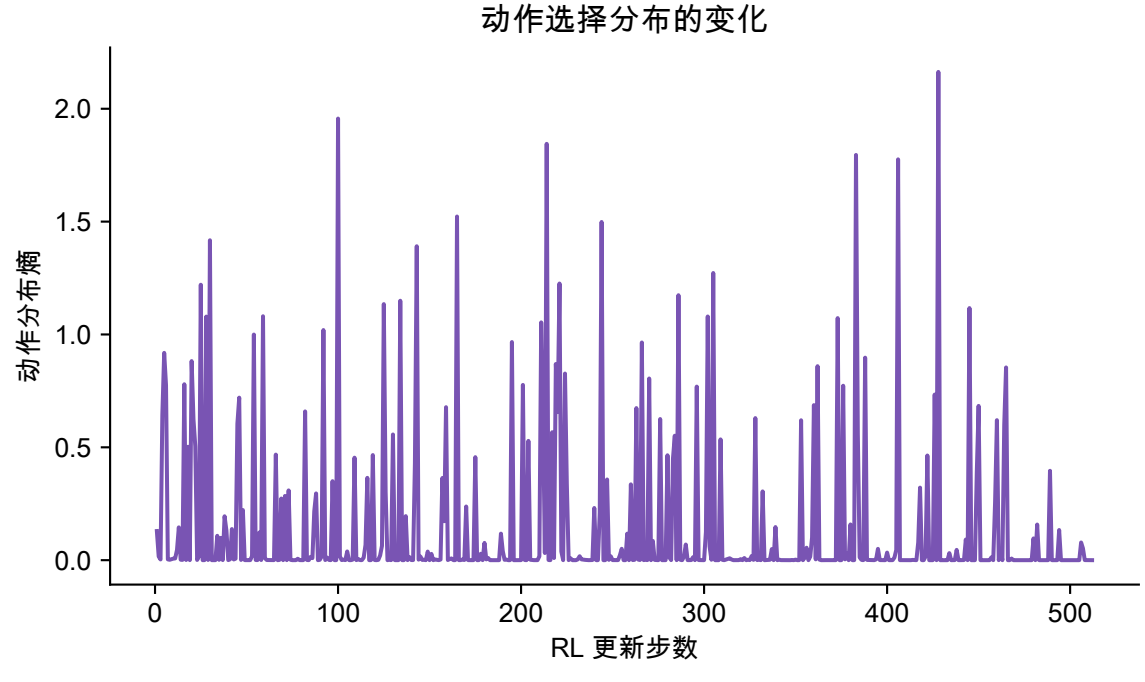
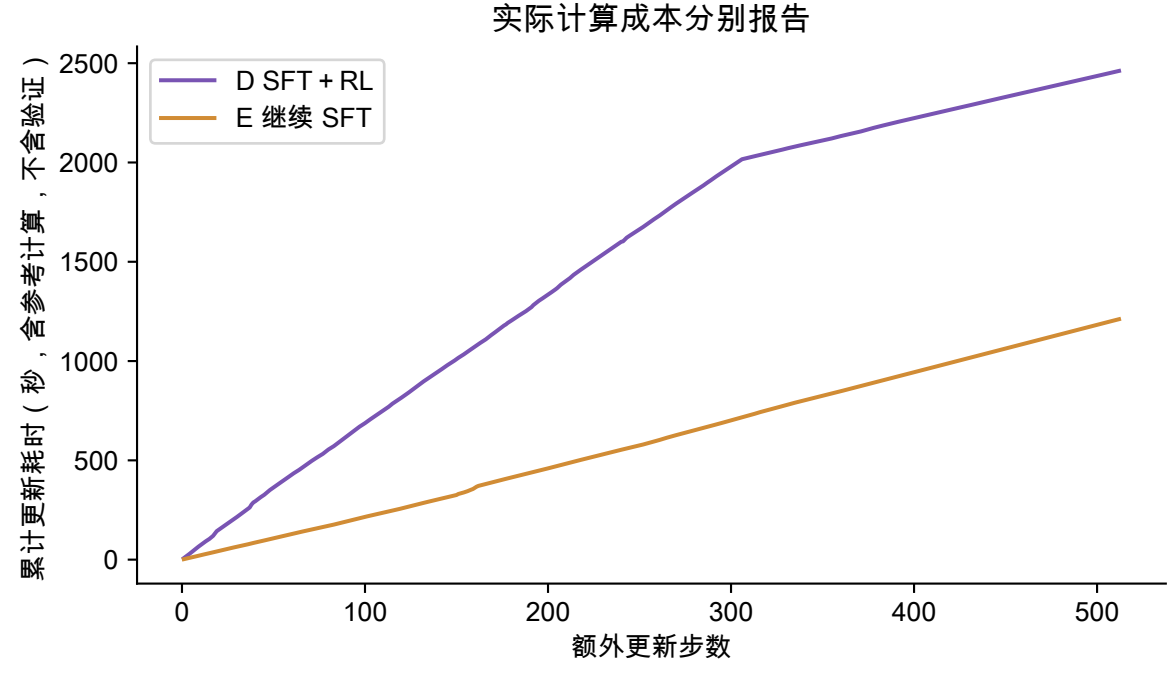

D SFT + RL 损失（数值不能跨图直接比较）
各自训练目标
额外更新步数


E 继续 SFT 损失（数值不能跨图直接比较）
各自训练目标
额外更新步数


动作选择分布的变化
动作分布熵
RL 更新步数


实际计算成本分别报告
D SFT + RL
E 继续 SFT
累计更新耗时（秒，含参考计算，不含验证）
额外更新步数